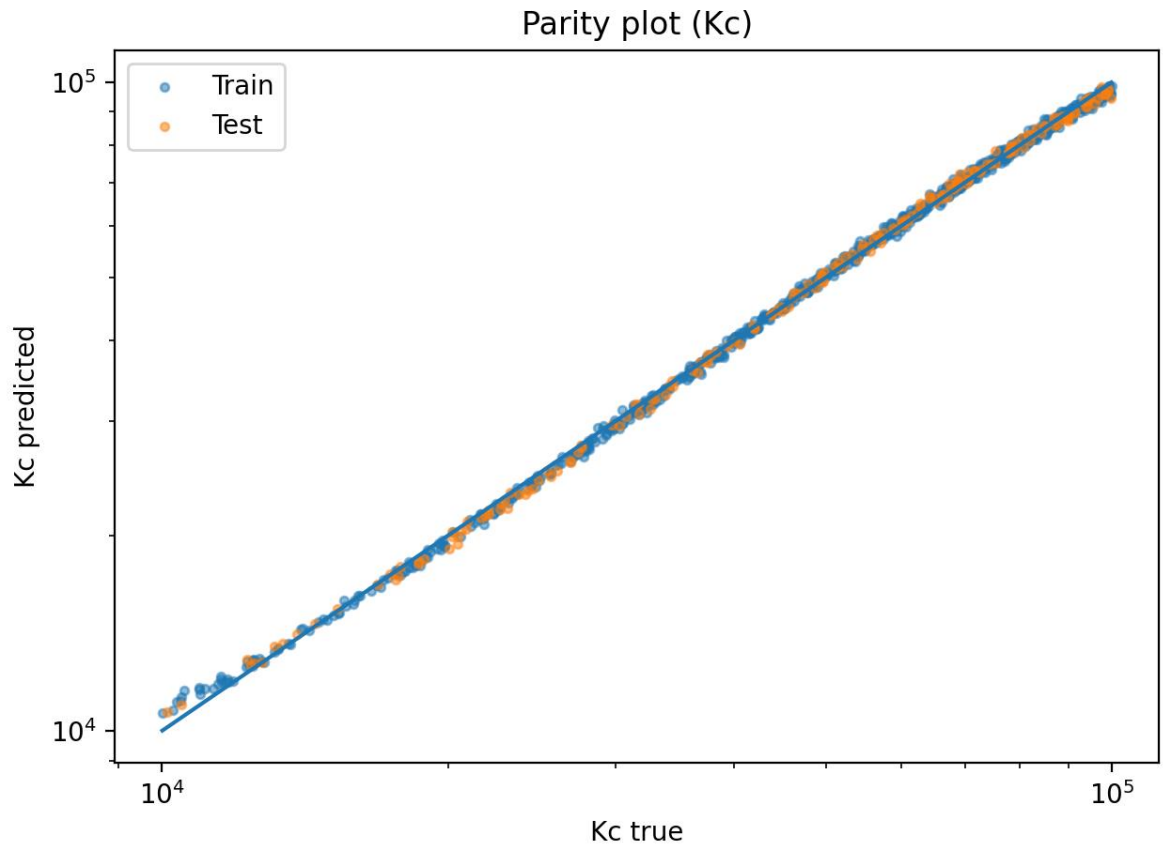



# Neural Network Training Results

## 1. Parity plot (Kc) - Train and Test



Este gráfico muestra el Kc que ha predicho el modelo (en azul los de entrenamiento y en naranja los de test) en el eje Y. En el eje X, tenemos los valores reales de Kc (los calculados a partir de la lorentziana de la traza → los que tiene que ajustar la NN). La diagonal representa la predicción perfecta del Kc. Como se puede apreciar, el modelo predice con bastante exactitud Kc, generalizando bien tanto para entrenamiento como test (datos no vistos antes por el modelo). Esto indica que no hay overfitting.

## 2. Residuals vs Kc (test)




Este gráfico muestra el error relativo del test (eje Y), es decir:

$$\frac{K_{c,\text{pred}} - K_{c,\text{true}}}{K_{c,\text{true}}}$$


frente a el Kc real de la traza (sin ruido). Se puede observar como Los residuos están centrados alrededor de 0, lo cual es ideal (error bajo consistente del modelo). La mayoría de los errores están dentro de  $\pm 2-3\%$ , por lo que tiene un % de acierto bastante alto.

### 3. Training Loss



Esta gráfica muestra cómo va variando la pérdida del modelo a lo largo de las epochs (iteraciones) de entrenamiento. Como se puede observar, el modelo aprende correctamente, reduciendo el error y realentizando su mejora en las epochs finales, lo que sugiere que 2000 es un número óptimo para lograr un equilibrio entre evitar sobreajuste y una máxima performance del modelo.

### 4. Error relativo vs Sigma (ruido)



Este gráfico muestra cómo van variando distintos errores en relación con el ruido de las muestras. Los errores se pueden entender como:

- **MAE** → error medio típico (precisión media)
- **RMSE** → error típico penalizando outliers
- **P95** → peor error razonable (95 % de los casos)

Como se puede observar, el modelo es robusto frente al ruido, ya que incluso en los peores casos (5%) del rango con más ruido, el error relativo solamente alcanza un 5% aproximadamente.